

# מערכת RAG לשאלות-תשובות על מוצרי טיפוח אלורה

פרויקט אמצע - קורס הנדסת AI  
מגישים: דביר מרגלית, אריאל אוברשטיין

## 1. מבוא ומטרה

מודלי שפה גדולים (LLM) סובלים משתי מגבלות מרכזיות: היעדר ידע על מקורות פרטיים או נישתיים שלא נכללו באימון, ונטייה ל"הזיות" - יצירת מידע שגוי בביטחון רב. גישת Retrieval-Augmented Generation (RAG) מתמודדת עם שתייה: היא מאחזרת קטעי מידע רלוונטיים ממאגר ידע חיצוני ומספקת אותם ל-LLM כהקשר, כך שהתשובה מעוגנת במקורות אמיתיים ולא בידע הפנימי בלבד.

בחרנו כתחום את מוצרי הטיפוח הטופיקליים של Forever Living (ג'לים, קרמים, תרסיסים). הנושא מתאים ל-RAG משלוש סיבות: ל-LLM אין ידע מדויק על הרכבי המוצרים הספציפיים; השאלות אובייקטיביות (רכיבים ותפקודיהם); וקיים מקור מידע עצמאי ואמין שניתן לאנדקס.

## 2. ארכיטקטורת המערכת

המערכת בנויה משני שלבים נפרדים. שלב האינדקס (חד-פעמי) כולל: איסוף דפי המקור, ניתוחם לטקסט נקי, חיתוך לקטעים, יצירת embeddings ואחסוןם באינדקס FAISS. שלב השאילתה (לכל שאלה) כולל: יצירת embedding לשאלה, אחזור top-k הקטעים הקרובים, בניית prompt עם ההקשר, ויצירת התשובה ב-LLM. ההפרדה מאפשרת עלות אינדקס חד-פעמית לצד זמן-שאילתה מהיר.

### החלטות עיצוב עיקריות

- **מודל Embedding:** intfloat/multilingual-e5-small (384 ממדים). חינומי, רץ על CPU, ורב-לשוני. שקלנו את e5-large אך ויתרנו עליו - איטי פי 4-3 תמורת שיפור איכות שולי בקורפוס בגודל זה.
- **אינדקס:** FAISS IndexFlatL2 - חיפוש מדויק (exact) ולא מקורב. מתאים לקורפוס הקטן (191 קטעים, אחזור מתחת ל-10 מילישניות). אינדקסים מקורבים כמו HNSW מיועדים למיליוני קטורים ומיותרים כאן.
- **מודל שפה:** Google Gemini 2.5-flash עם temperature=0. בחרנו temperature נמוך כי מערכת עובדתית צריכה תשובות דטרמיניסטיות ועקביות; ערך גבוה היה מגדיל את הסיכון להזיות ולחוסר שחזוריות.
- **מניעת הזיות:** prompt מחמיר המורה למודל לענות אך ורק מתוך ההקשר, לצטט את שם המוצר לכל טענה, ולהשיב "אין מספיק מידע" כאשר התשובה אינה בהקשר. נאסרו טענות רפואיות.

## 3. קורפוס ואסטרטגיית חיתוך

המקור: **InclDecoder.com** - אתר ניתוח רכיבים קוסמטיים עצמאי, שאינו בבעלות Forever ובעל אופי מדעי ולא שיווקי. בחירה זו מבטיחה מידע אובייקטיבי. אספנו 9 מוצרים המכילים 182 רכיבים, בהיקף כולל של כ-109,000 תווים (כ-36 עמודים) - מעל סף 30 העמודים הנדרש.

מימשנו שתי אסטרטגיות חיתוך: structural (קטע נפרד לכל רכיב - יחידה סמנטית קוהרנטית) ו-fixed (חלונות באורך 600 תווים עם חפיפה של 100). הצינור הראשי משתמש ב-structural ומפיק 191 קטעים. השוואה בין השתיים מופיעה בניתוח ה-Ablation.

## 4. הערכה

בנינו gold set של 148 שאלות בארבעה סוגים: 122 שאלות ישירות (מכילות שם רכיב), 9 שאלות ברמת מוצר, 14 שאלות מנוסחות-מחדש (paraphrased - מתארות תפקיד בלבד ללא שם הרכיב), ו-3 שאלות סירוב (תשובתן אינה בקורפוס). הפרדנו בין הערכת האחזור (retrieval) להערכת התשובה (answer).

### הערכת אחזור (Retrieval)

| תוצאה | מדד / סוג שאלה                   |
|-------|----------------------------------|
| 99.3% | Hit@5 כללי                       |
| 0.979 | MRR                              |
| 100%  | שאלות ישירות (ingredient)        |
| 100%  | שאלות מוצר (product)             |
| 92.9% | שאלות מנוסחות-מחדש (paraphrased) |

ממצא מרכזי: השאלות הישירות, המכילות את שם הרכיב, אוחרו באופן טריוויאלי (100%), בעוד השאלות המנוסחות-מחדש - הדורשות הבנה סמנטית ולא התאמת מילות מפתח - השיגו 92.9%. הפער מדגים שהאתגר האמיתי באחזור הוא ההבנה הסמנטית.

### הערכת תשובה (Answer)

| תוצאה      | מדד                             |
|------------|---------------------------------|
| 3/3 (100%) | דיוק סירוב (anti-hallucination) |
| 9/9 (100%) | תשובות עם ציטוט מקור            |

כל שלוש שאלות הסירוב (כולל טענות רפואיות ושאלת מחיר שאינה בקורפוס) קיבלו סירוב נכון, מה שמוכיח שמנגנון מניעת ההזיות פועל. כל התשובות העובדתיות שנבדקו היו מעוגנות במקור ומצוטטות. בולט שבשאלות מנוסחות-מחדש המערכת חיברה נכון תפקוד לרכיב ללא הופעת שם הרכיב בשאלה (למשל "רכיב שמרגיע עור?" הניב Allantoin).

### 5. ניתוח שגיאות

השאלה היחידה שנכשלה באחזור הייתה "Which ingredient helps brighten the skin?". הרכיב הרלוונטי (Ascorbic Acid / ויטמין C) מתואר בקטע ארוך (730 תווים) המכסה 7-8 תפקודים שונים: אנטיאוקסידנט, הבהרה, איזון pH, ייצור קולגן, דהייט פיגמנטציה ועוד. אנו משערים שריבוי הנושאים בקטע יחיד **מדלל את האות הסמנטי** של כל תפקוד בודד: ה-embedding של הקטע הופך ל"ממוצע" של נושאים רבים, ולכן דמיונו לשאלה הקצרה והממוקדת על הבהרה נחלש. ממצא זה מדגיש את חשיבות אסטרטגיית החיתוך, ומוביל ישירות ל-Ablation הבא.

### 6. ניסוי Ablation

#### Ablation 1: עומק האחזור (top-k)

| k  | Hit@k  | MRR   |
|----|--------|-------|
| 1  | 97.2%  | 0.972 |
| 3  | 97.9%  | 0.976 |
| 5  | 99.3%  | 0.979 |
| 10 | 100.0% | 0.980 |

כבר ב-k=1 האחזור חזק (97.2%), כלומר הקטע הרלוונטי כמעט תמיד מדורג ראשון (תואם MRR גבוה). הגדלת k משפרת את הכיסוי עד 100% ב-k=10, אך על חשבון הכנסת קטעים פחות רלוונטיים להקשר ה-LLM (יותר רעש ועלות טוקנים). בחרנו k=5 כאיזון בין כיסוי לדיוק.

#### Ablation 2: אסטרטגיית חיתוך (structural מול fixed)

השווינו את שתי אסטרטגיות החיתוך באמצעות קריטריון רלוונטיות מבוסס-תוכן (האם הרכיב הנכון הופיע בקטעים שאוחזרו), כדי שההשוואה תהיה הוגנת ובלתי תלויה במזהי הקטעים.

| אסטרטגיה              | מס' קטעים | Content Hit@5 |
|-----------------------|-----------|---------------|
| Structural (לפי רכיב) | 191       | 91.8%         |

|                   |     |       |
|-------------------|-----|-------|
| Fixed (600 תווים) | 219 | 88.5% |
|-------------------|-----|-------|

Structural ניצח (91.8% מול 88.5%) למרות שיצר פחות קטעים. ההסבר: קטעי structural הם יחידות סמנטיות קוהרנטיות (רכיב = מושג), בעוד fixed מפצל תיאורי רכיבים באופן שרירותי ומטשטש את הייצוג. הניתוח גם חשף שרכיבים בעלי תיאור דליל (תמציות צמחיות) קשים לאחזור ללא תלות באסטרטגיה. תוצאה זו מספקת ביסוס אמפירי לבחירה ב-structural.

## 7. מגבלות ועבודה עתידית

- השאלות האוטומטיות בקורפוס מוטות לקלות (מכילות מילות מפתח); הערכה אמינה דרשה הוספת שאלות מנוסחות-מחדש. ניתן להרחיב בעתיד את מבחן השאלות הקשות.
- **שאלות אגרגטיביות (גלובליות):** המערכת חלשה בשאלות על הקורפוס כולו (למשל "כמה מוצרים קיימים?"). מכיוון שהאחזור מחזיר רק top\_k קטעים, ה-LLM אינו רואה את כל הקורפוס בבת אחת ועלול לספור שגוי (השיב 5 במקום 9). זו מגבלה ארכיטקטונית של גישת האחזור - ולא הזיה, שכן המערכת נאמנה למה שאוחזר. פתרון אפשרי: שכבת מטא-דאטה או ניתוב שאלות (query routing) שמפנה שאלות גלובליות למסלול נפרד.
- רכיבים בעלי תיאור דליל (תמציות צמחיות) קשים לאחזור - מגבלת תוכן של המקור.
- המערכת מסתמכת על מקור יחיד (InclDecoder). הרחבה עתידית: שילוב קטלוגים רשמיים של Forever ומאמרים מדעיים (PubMed) ליצירת קורפוס רב-מקורי.
- מודל ה-embedding קטן (e5-small); מודל גדול או ייעודי-תחום עשוי לשפר את האחזור בשאלות סמנטיות, כפי שעלה מניתוח השגיאות.